UNIVERSIDADE EDUARDO MONDLANE

FACULDADE DE ENGENHARIA

DEPARTAMENTO DE ENGENHARIA ELECTROTÉCNICA

Inteligência Artificial

Resolução de Problemas Por Meio de Busca
Busca Informada
Parte 2/2

Docentes: Eng Roxan Cadir
Eng Ruben Manhiça

Maputo, 7 de outubro de 2024

Conteúdo da Aula

1. Resolução de Problemas Por meio de Buscas
2. Algoritmos de busca Informada

Busca com informação e exploração

Capítulo 4 – Russell & Norvig

Secção 4.2 e 4.3

Revisão da aula passada: Busca A*

- Ideia: evitar expandir caminhos que já são caros
- Função de avaliação $f(n) = g(n) + h(n)$
  - $g(n)$ = custo até o momento para alcançar n
  - $h(n)$ = custo estimado de n até o objetivo
  - $f(n)$ = custo total estimado do caminho através de n até o objetivo.

Revisão da aula passada: Heurística Admissível

- Uma heurística *h(n)* é admissível se para cada nó *n*,

  $h(n) \leq h^*(n)$, onde $h^*(n)$ é o custo verdadeiro de alcançar o estado objetivo a partir de *n*.
- Uma heurística admissível nunca superestima o custo de alcançar o objetivo, isto é, ela é optimista.
- Exemplo: $h_{DLR}(n)$ (distância em linha reta nunca é maior que distância pela estrada).
- Teorema: Se *h(n)* é admissível, A* usando algoritmo `BUSCA-EM-ARVORE` é óptima.

Exemplo: Heurísticas Admissíveis

- Para o quebra-cabeça de 8 peças:
  - $h_1(n)$ = número de peças fora da posição
  - $h_2(n)$ = distância "Manhattan" total (para cada peça calcular a distância em "quadras" até a sua posição) – TPC: Investigar sobre Distancia de Manhattan

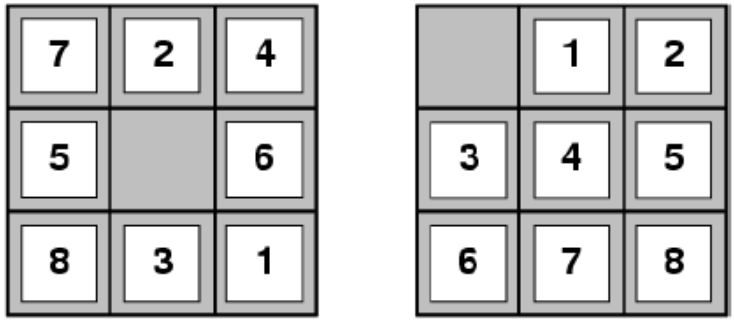

- $h_1(S) = ?$ 8
- $h_2(S) = ?$ 3+1+2+2+2+3+3+2 = 18

Medindo a qualidade de uma heurística

- Fator de ramificação efetiva
  - A* gera **N** nós
  - Profundidade da solução é **d**
  - Supondo uma árvore uniforme, podemos calcular o fator de ramificação efetiva b* a partir de

$$N+1 = 1 + b^* + (b^*)^2 + \ldots + (b^*)^d$$

Exemplo

Se A* encontra a solução optima na profundidade 5, usando 52 nós, qual é o valor do factor de ramificação efectivo?

Exemplo:
Quebra-cabeça de 8 peças

	Custo da busca			Fator de ramificação efetiva		
d	BAI	$A^*(h_1)$	$A^*(h_2)$	BAI	$A^*(h_1)$	$A^*(h_2)$
2	10	6	6	2,45	1,79	1,79
4	112	13	12	2,87	1,48	1,45
6	680	20	18	2,73	1,34	1,30
8	6384	39	25	2,80	1,33	1,24
10	47127	93	39	2,79	1,38	1,22
12	3644035	227	73	2,78	1,42	1,24
14	–	539	113	–	1,44	1,23
16	–	1301	211	–	1,45	1,25
18	–	3056	363	–	1,46	1,26
20	–	7276	676	–	1,47	1,27
22	–	18094	1219	–	1,48	1,28
24	–	39135	1641	–	1,48	1,26

Como criar heurísticas admissíveis?

1. A solução de uma simplificação de um problema (problema relaxado) é uma heurística para o problema original.
   - **Admissível**: a solução do problema relaxado não vai superestimar a do problema original.
   - É **consistente** para o problema original se for consistente para o relaxado.

Exemplo:
Quebra-cabeça de 8 peças

- h_1 daria a solução óptima para um problema "relaxado" em que as peças pudessem se deslocar para qualquer lugar.
- h_2 daria a solução óptima para um problema "relaxado" em que as peças pudessem se mover um quadrado por vez em qualquer direção.

Como criar heurísticas admissíveis?

2. Usar o custo da solução de um subproblema do problema original.

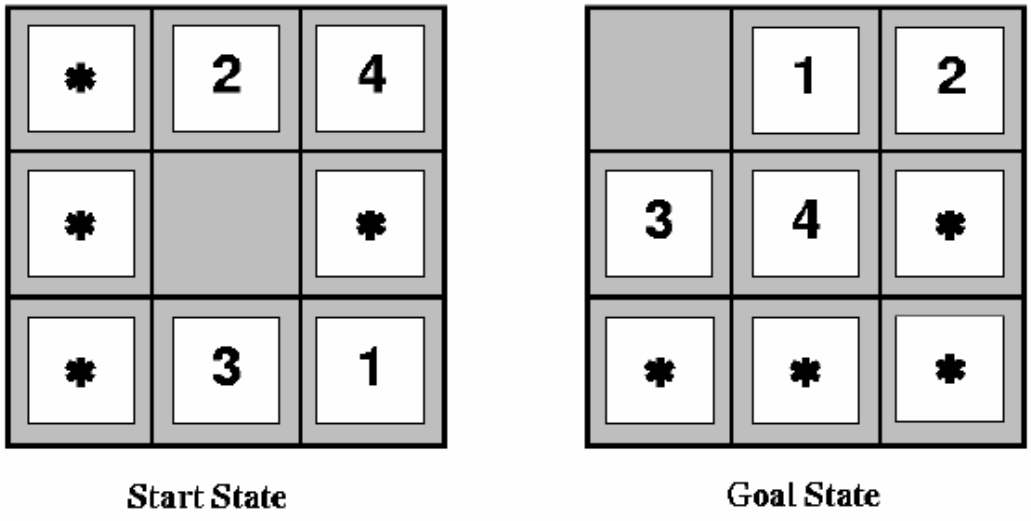

Calcular o custo da solução exacta sem se preocupar com os *
Limite inferior do custo do problema completo

Como criar heurísticas admissíveis?

3. Base de dados de padrões:
   - Armazenar o custo exacto das soluções de muitos subproblemas.
   - Para um determinado estado procurar o subproblema referentes àquele estado.
   - Exemplo: todas as configurações das 4 peças na figura anterior.

Algoritmos de Busca Local

- Em muitos problemas de optimização o caminho para o objetivo é irrelevante.
  - Queremos apenas encontrar o estado objetivo, não importando a sequência de acções.
  - Espaço de estados = conjunto de configurações completas.
    - Queremos encontrar a melhor configuração.
  - Neste caso podemos usar algoritmos de busca local.
    - Mantêm apenas o estado actual, sem a necessidade de manter a árvore de busca.

Exemplo: *n*-rainhas

- Colocar *n* rainhas em um tabuleiro *nxn*, sendo que cada linha coluna ou diagonal pode ter apenas uma rainha.

Busca de Subida de Encosta (Hill-Climbing)

- "É como subir o Everest em meio a um nevoeiro durante uma crise de amnésia"

```
função SUBIDA-DE-ENCOSTA(problema) retorna um estado que é um máximo local
  entradas: problema, um problema
  variáveis locais: corrente, um nó
                    vizinho, um nó

  corrente ← CRIAR-NÓ(ESTADO-INICIAL[problema])
  repita
    vizinho ← um sucessor de corrente com valor mais alto
    se VALOR[vizinho] ≤ VALOR[corrente] então retornar ESTADO[corrente]
    corrente ← vizinho
```

Busca de Subida de Encosta

- Elevação é a função objetivo: queremos encontrar o máximo global.
- Elevação é o custo: queremos encontrar o mínimo global.
- O algoritmo consiste em uma repetição que percorre o espaço de estados no sentido do valor crescente (ou decrescente).
- Termina quando encontra um pico (ou vale) em que nenhuma vizinho tem valor mais alto.

Busca de Subida de Encosta

- Não mantém uma árvore, o nó atual só registra o estado actual e o valor da função objetivo.
- Não examina antecipadamente valores de estados além dos valores dos vizinhos imediatos do estado actual.

Busca de Subida de Encosta

- Problema: dependendo do estado inicial pode ficar presa em máximos (ou mínimos) locais.

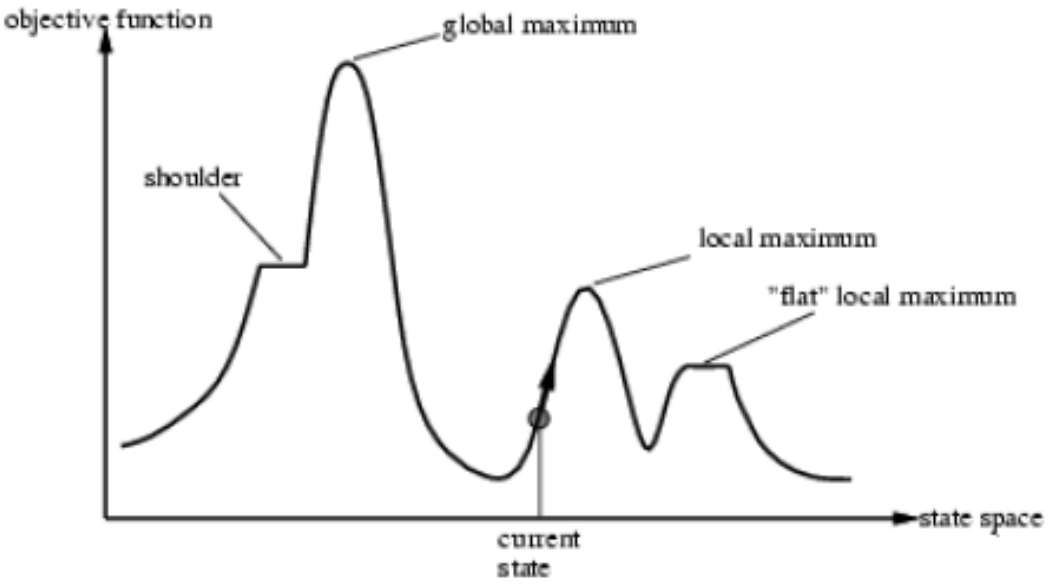

Busca de Subida de Encosta: Problema das 8-rainhas

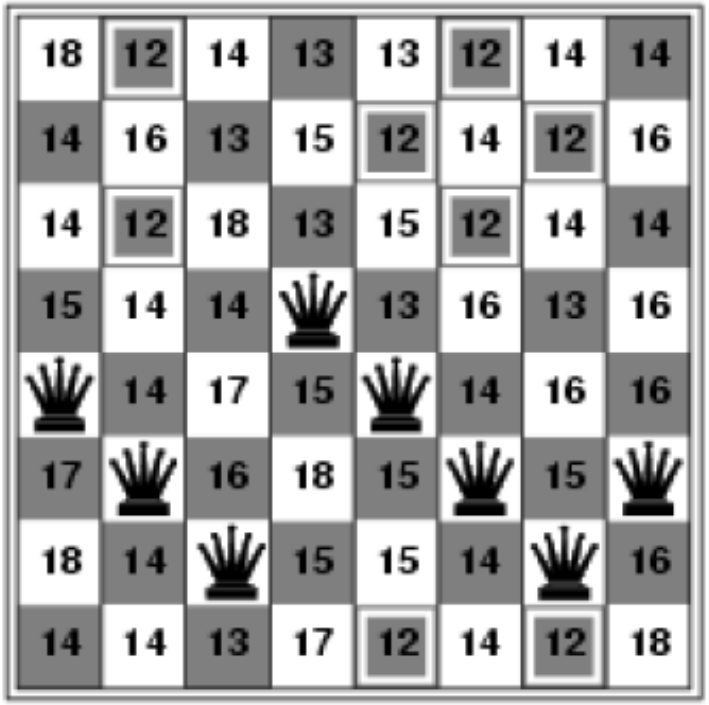

- *h* = número de pares de rainhas que estão "se atacando", direta ou indiretamente
- *h = 17* para o estado acima
- Em cada quadrado, valor de h para cada sucessor possível obtido pela **movimentação de uma** rainha dentro de sua coluna

Busca de Subida de Encosta: Problema das 8-rainhas

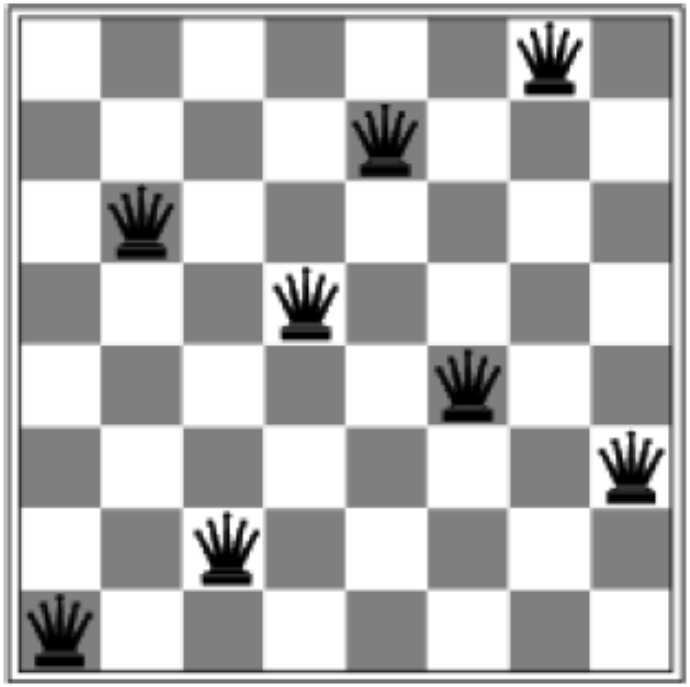

- Um mínimo local com $h = 1$.

Busca de têmpera simulada (simulated annealing)

- Combina o Hill-Climbing com um percurso aleatório resultando em eficiência e completeza.
- Subida de encosta dando uma “chacoalhada” nos estados sucessores.
  - Estados com avaliação pior podem ser escolhidos com uma certa probabilidade.
  - Esta probabilidade diminui com o tempo.

Busca de têmpera simulada

- Escapa de máximos locais permitindo alguns passos "maus" mas gradualmente decresce a sua frequência.

```
função TÊMPERA-SIMULADA(problema, escalonamento) retorna um estado solução
  entradas: problema, um problema
            escalonamento, um mapeamento de tempo para "temperatura"
  variáveis locais: corrente, um nó
                    próximo, um nó
                    T, uma "temperatura" que controla a probabilidade de passos descendentes

  corrente ← CRIAR-NÓ(ESTADO-INICIAL[problema])
  para t ← 1 até ∞ faça
      T ← escalonamento[t]
      se T = 0 então retornar corrente
      próximo ← um sucessor de corrente selecionado ao acaso
      ΔE ← VALOR[próximo] – VALOR[corrente]
      se ΔE > 0 então corrente ← próximo
      senão corrente ← próximo somente com probabilidade e^(ΔE/T)
```

Propriedades da busca de têmpera simulada

- Pode-se provar que se T decresce devagar o suficiente, a busca pode achar uma solução óptima global com probabilidade tendendo a 1.
- Muito usada em projetos de circuitos integrados, layout de instalações industriais, optimização de redes de telecomunicações, etc.

Busca em feixe local

- Manter *k* estados ao invés de um.
- Começa com *k* estados gerados aleatoriamente.
- A cada iteração, todos os sucessores dos *k* estados são gerados.
- Se qualquer um deles for o estado objetivo, a busca para; senão seleciona-se os *k* melhores estados da lista pra continuar.

Algoritmos genéticos

- Um estado sucessor é gerado através da combinação de dois estados pais.
- Começa com *k* estados gerados aleatoriamente (população).
- Um estado é representado por uma string de um alfabeto finito (normalmente strings de 0s e 1s).
- Função de avaliação (função de fitness). Valores mais altos pra estados melhores.
- Produz a próxima geração de estados por **seleção, mutação e crossover. (TPC – ler capitulo 4.3)**

TPC

- Ler os capítulos 4.2 e 4.3
- Ler os capítulos 4.4 e 4.5
- Resolver os exercícios: 4.1; 4.2; 4.3;4.5; 4.11!

FIM!!!

Duvidas e Questões?